

Machine Learning para Finanzas

Clase 3

César Núñez Cuevas


`cnunezc@fen.uchile.cl`





UNIVERSIDAD

Finis Terrae

Workflow



Modelos Supervisados



Definición del Problema: Credit Scoring

En el sector financiero, el **Credit Scoring** busca estimar la probabilidad de que un cliente no cumpla con sus obligaciones contractuales (*Default*).

- **Variable Objetivo (Y):** Binaria (1: Default, 0: No Default).
- **Variables Predictoras (X):** Edad, ingresos, historial crediticio, ratio de deuda, etc.
- **Meta:** Estimar la $P(Y = 1|X)$.

Datos de default

Attribute		Type	Description/Values
Personal	age	num	Age of the potential client
	job	cat	admin., blue- collar, entrepreneur, housemaid,... ,unknown
	marital.status	cat	divorced, married, single, unknown
	education	cat	basic.4y, basic.6y, basic.9y, high.school,... unknown
Bank	default	cat	The client has credit in default: no,yes,unknown
	housing loan	cat	The client has a housing loan contract: no,yes,unknown
	loan	cat	The client has a personal loan: no,yes,unknown
Campain	contact	cat	Communication type: cellular,telephone
	month	cat	Last month contacted: jan, feb ,..., dec
	day_of_week	cat	Last contact day : mon, tue,..., fri
	duration	num	Last contact duration (in seconds)
	campaign	num	Number of contacts performed during this campaign
	pdays	num	Number of days that passed by after last contact
	previous	num	Number of contacts performed before this campaign
	poutcome	cat	Outcome of the previous marketing campaign: failure,nonexistent,success
Economical	emp.var.rate	num	Employment variation rate in the last quarter
	cons.price.idx	num	Consumer price index in the last month
	cons.conf.idx	num	Monthly consumer confidence index
	euribor3m	num	Dayly Euro Interbank Offered Rate
	nr.employed	num	Number of employed citizens in the last quarter (thousands)
Target	success	target	0: no, 1: yes

¹ A data-driven approach to predict the success of bank telemarketing. S. Moroa, P. Cortez, P. Rita.Decision Support Systems, 62:22-31, 2014.

Modelo de Probabilidad Lineal (LPM)

El enfoque más simple es aplicar Mínimos Cuadrados Ordinarios (OLS) directamente:


$$Y = Xw + \epsilon$$

$$w^* = (X^T X)^{-1} X^T y$$

Limitaciones críticas en Finanzas:

- 1 Las predicciones $\hat{Y}$ pueden estar fuera del rango $[0, 1]$.
- 2 Los errores ϵ son intrínsecamente heterocedásticos.
- 3 La relación lineal no captura la naturaleza saturada del riesgo.

Modelo de Probabilidad Lineal (LPM)



Modelo de Probabilidad Lineal (LPM)

- Lineal

$$Y = b + \sum_{j=1}^n w_j X_j = b + w_1 X_1 + w_2 X_2 + \cdots + w_n X_n = b + \mathbf{X}\mathbf{w}$$

- Cuadrático

$$Y = b + \mathbf{X}\mathbf{w} + \mathbf{X}^2\mathbf{d}$$

- Exponencial

$$Y = e^{b+\mathbf{X}\mathbf{w}}$$

Regresión Lineal

	coef	std err	t	P> t	[0.025	0.975]
const	22.5693	0.245	92.144	0.000	22.088	23.051
CRIM	-0.8678	0.298	-2.909	0.004	-1.455	-0.281
ZN	0.9310	0.365	2.551	0.011	0.213	1.649
INDUS	0.5166	0.494	1.045	0.297	-0.456	1.489
CHAS	0.0671	0.270	0.249	0.804	-0.463	0.598
NOX	-1.6601	0.532	-3.121	0.002	-2.706	-0.614
RM	3.3925	0.340	9.971	0.000	2.723	4.062
AGE	-0.2093	0.429	-0.488	0.626	-1.052	0.634
DIS	-2.7910	0.475	-5.879	0.000	-3.725	-1.857
RAD	2.3790	0.650	3.660	0.000	1.100	3.658
TAX	-2.1962	0.718	-3.059	0.002	-3.608	-0.784
PTRATIO	-2.0690	0.325	-6.372	0.000	-2.708	-1.430
B	0.5860	0.298	1.965	0.050	-0.001	1.173
LSTAT	-3.4712	0.432	-8.032	0.000	-4.321	-2.621

Regresión Logística: El Estándar de la Industria

Para forzar que la salida sea una probabilidad, utilizamos la **función Logit**:


$$P(Y = 1|X) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

donde z es la combinación lineal de los predictores:

$$z = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

Esta función sigmoide asegura que el riesgo se mantenga siempre en el intervalo biológicamente y financieramente lógico de 0 a 1.

Regresión Logística



$$\log \frac{P(y = 1|x)}{P(y = 0|x)} = w_0 + w_1x_1 + \cdots + w_nx_n \\ = \mathbf{w}^\top \mathbf{x}$$

$$P(y = 0|x) = \frac{1}{1 + e^{\mathbf{w}\mathbf{x}}}$$

Interpretación de Coeficientes y Odds

A diferencia de la regresión lineal, el coeficiente β_i representa el cambio en el *log-odds*:

$$\ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1$$


- **Odds Ratio (e^{β_i}):** Indica cuánto aumenta o disminuye la posibilidad de default ante un cambio unitario en X_i .
- Si $e^{\beta_i} > 1$, la variable aumenta el riesgo de impago.
- Si $e^{\beta_i} < 1$, la variable es un factor de protección.

Support Vector Machines: Máximo Margen


SVM busca el hiperplano que maximiza la distancia entre las clases de clientes (solventes vs. insolventes).

- **Vectores de Soporte:** Son los clientes "límite", los más difíciles de clasificar.
- **Función de Decisión:** $f(x) = \text{sign}(w^T x + b)$.
- En finanzas, SVM es útil cuando los datos no son linealmente separables mediante el uso de *Kernels*.

Support Vector Machine




Support Vector Machine - Linealmente Separables




$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s. t.} \quad & y_i(\mathbf{w}'\mathbf{x}_i - b) \geq 1 \quad i \in \mathcal{M} \end{aligned}$$

Support Vector Machine - Caso General


$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 \\ \text{s. t.} \quad & y_i(\mathbf{w}'\mathbf{x}_i - b) \geq 1 \quad i \in \mathcal{M} \end{aligned}$$




$$\begin{aligned} \min_{\mathbf{w}, b, d} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + \lambda \sum_{i=1}^m d_i \\ \text{s. t.} \quad & y_i(\mathbf{w}'\mathbf{x}_i - b) \geq 1 - d_i \quad i \in \mathcal{M} \\ & d_i \geq 0 \quad i \in \mathcal{M} \end{aligned}$$



Support Vector Machine - Kernels



Support Vector Machine - Generales







$$\min_{w, b, d} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m d_i$$

$$\text{subject to } y_i (w^T \underbrace{\phi(x_i)}_{\text{kernel}} - b) \geq 1 - d_i,$$

$$d_i \geq 0$$

Main Parameters

- ▶ C : Inverse of regularization strength
- ▶ kernel:
 - linear: $x'x$
 - poly: $(\gamma x'x + r)^d$
 - rbf: $\exp(-\gamma \|x - x'\|^2)$
 - sigmoid: $\tanh(\gamma x'x + r)$
- ▶ degree(d), gamma(γ), coef0(r)
- ▶ Resolution algorithm parameters



Margen Rígido vs. Margen Flexible

En datos reales de crédito, las clases siempre se solapan. SVM utiliza una **Variable de Holgura** (ξ):

$$\text{mín } \frac{1}{2} \|w\|^2 + C \sum \xi_i$$

- El parámetro C controla el compromiso entre maximizar el margen y minimizar el error de clasificación.
- Un C alto penaliza errores (modelo complejo), un C bajo permite más errores (modelo robusto).

Del Score a la Decisión

El modelo entrega una probabilidad (ej. 0.35). El banco debe elegir un **Cut-off** (k):

Si $P(Y = 1) > k \rightarrow$ Rechazar Crédito

Si $P(Y = 1) \leq k \rightarrow$ Aprobar Crédito

La elección de k depende del apetito de riesgo de la institución y el costo de capital.

Regresión Ridge: Regularización y Multicolinealidad

Ridge aborda el problema de la varianza extrema cuando las variables financieras están altamente correlacionadas.

- **Trasfondo Matemático:** Minimiza $RSS + \lambda \sum_{j=1}^p \beta_j^2$. La penalización $L2$ es una esfera en el espacio de parámetros.
- **Trade-off Sesgo-Varianza:** Al aumentar λ , los coeficientes se encogen hacia cero asintóticamente, reduciendo la sensibilidad al ruido del *Train Set*.
- **Uso en Finanzas:** Ideal cuando se tienen múltiples indicadores macroeconómicos que se mueven juntos; evita que el modelo asigne pesos absurdos a variables redundantes.

Regresión Lasso: Sparse Models y Selección de Rasgos

Lasso realiza una selección automática de variables al permitir que los coeficientes sean exactamente cero.

- **Geometría de la Penalización:** El uso del valor absoluto $|\beta_j|$ crea una región de restricción con “esquinas” (diamante), facilitando que la solución óptima toque los ejes.
- **Interpretabilidad:** Genera modelos parsimoniosos (simples). En un dataset con 100 ratios financieros, Lasso puede identificar los 5 que realmente predicen el riesgo.
- **Limitación:** Si hay un grupo de variables muy correlacionadas, Lasso tiende a seleccionar una al azar y descartar las demás, a diferencia de Ridge.

KNN Regressor: Estimación Local No Paramétrica

KNN no asume una forma lineal; predice basándose en la estructura local de los datos de entrenamiento.

- **Cálculo de la Predicción:** $\hat{y} = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i$. Es un promedio simple (o ponderado por distancia) de los vecinos.
- **Maldición de la Dimensionalidad:** En espacios de muchas dimensiones (muchas variables), la "distancia" se vuelve menos significativa, degradando el desempeño.
- **Preprocesamiento Crítico:** Es obligatorio el escalado de variables (StandardScaler) para que una variable con rango grande (ej. Saldo Bancario) no opaque a una pequeña (ej. Edad).

Decision Tree Regressor: Partición del Espacio de Estados

El árbol de regresión divide el dataset en regiones R_m donde la respuesta es constante.

- **Criterio de División:** Se busca el par (variable j , umbral s) que minimice la suma de cuadrados residuales:

$$RSS = \sum_{i: x_i \in R_1(j,s)} (y_i - \hat{y}_{R1})^2 + \sum_{i: x_i \in R_2(j,s)} (y_i - \hat{y}_{R2})^2.$$

- **Profundidad vs. Error:** Un árbol muy profundo captura cada fluctuación del *Train Set* (Overfitting), mientras que uno muy corto no captura la tendencia (Underfitting).
- **Métricas de Evaluación:** Se analiza el Residuo ($y - \hat{y}$) para verificar si el modelo comete errores sistemáticos en ciertos rangos de valores financieros.

MLP Regressor: Redes Neuronales para Regresión

El MLP es un modelo de aprendizaje profundo que captura relaciones altamente no lineales mediante capas de neuronas interconectadas.

- **Arquitectura:** Se compone de una capa de entrada, una o más capas ocultas con funciones de activación (ej. ReLU) y una capa de salida con activación lineal para valores continuos.
- **Proceso de Aprendizaje:** Utiliza el algoritmo de *Backpropagation* y optimizadores como Adam para minimizar la función de pérdida (MSE).
- **Sensibilidad:** Requiere un ajuste fino de hiperparámetros (número de neuronas, capas y tasa de aprendizaje) y es extremadamente sensible a la escala de los datos.
- **Aplicación:** Útil en finanzas para modelos de valoración de activos complejos donde las interacciones entre variables no son evidentes.

Ensemble Regressors: El Poder de la Agregación (Bagging)

Los métodos de ensamble combinan múltiples modelos base para reducir el error de generalización y la varianza.

- **Random Forest Regressor:** Entrena múltiples árboles de decisión sobre subconjuntos aleatorios de datos (Bootstrap) y variables.
- **Predicción Final:** El resultado es el promedio de las predicciones de todos los árboles individuales, lo que suaviza las estimaciones y reduce el overfitting.
- **Ventaja Competitiva:** Proporciona mayor estabilidad que un solo árbol de decisión y maneja de forma natural la importancia de las variables en el riesgo.

Ensemble Regressors: Aprendizaje Secuencial (Boosting)

A diferencia del Bagging, el Boosting entrena modelos de forma secuencial para corregir los errores de los modelos anteriores.

- **Gradient Boosting (XGBoost/LightGBM):** Cada nuevo árbol se entrena para predecir los *residuos* (errores) del ensamble actual, optimizando el gradiente de la función de pérdida.
- **AdaBoost Regressor:** Ajusta los pesos de las muestras, dando más importancia a aquellas donde el error de predicción fue mayor en la ronda previa.
- **Desempeño en Finanzas:** Estos modelos suelen ofrecer la mayor precisión en la industria para tareas de regresión, aunque requieren una validación cruzada rigurosa.

Flujo de Datos: Entrenamiento, Prueba e Inferencia

El éxito de un modelo financiero depende de cómo gestionamos la información en sus distintas etapas.

- **Conjunto de Entrenamiento (Train Set):** Es el material de estudio del modelo. Aquí el algoritmo ajusta sus parámetros internos para aprender los patrones de riesgo o fraude.
- **Conjunto de Prueba (Test Set):** Actúa como un “examen final”. Se le entrega al modelo como **información nueva** que no ha visto antes para verificar si realmente aprendió a generalizar o si solo memorizó.
- **Predicción con Nuevos Datasets (Inferencia):** Una vez validado, el modelo se exporta para recibir datos de producción (ej. solicitudes de crédito del día de hoy).
 - ▶ El nuevo dataset debe pasar por el **mismo preprocesamiento** que el de entrenamiento (Pandas/Limpieza).
 - ▶ Se utiliza la función `.predict()` para obtener la clasificación final del cliente.

Anatomía de la División Train/Test

Dividimos el dataset original en subconjuntos disjuntos:

- **Train Set (70-80 %):** Se utiliza para que el algoritmo ajuste sus parámetros internos (ej. pesos de una red o cortes de un árbol).
- **Test Set (20-30 %):** Datos "vistos" por primera vez para reportar métricas finales como el AUC o F-score.
- **Importante:** En finanzas, esta división suele ser *temporal* para evitar el sesgo de supervivencia.

Hiperparámetros en Modelos Lineales

En modelos lineales y de regresión, los hiperparámetros controlan la complejidad y la capacidad de generalización.

- **Regularización (C):** En Regresión Logística y SVM, C controla el compromiso entre un error bajo en entrenamiento y un margen amplio (evita el overfitting).
- **Tipo de Penalización:** Elección entre $L1$ (Lasso), $L2$ (Ridge) o *ElasticNet* para selección de variables financieras.
- **Epsilon (ϵ):** En Support Vector Regression (SVR), define el "tubo" donde no se penalizan los errores.

Mecánica de GridSearch para Regresión

GridSearch realiza una búsqueda exhaustiva sobre un subconjunto especificado del espacio de hiperparámetros.

- Se define una rejilla" de valores, por ejemplo: $C \in \{0,1,1,10,100\}$.
- El algoritmo entrena el modelo para **cada combinación** posible de la rejilla.
- Es costoso computacionalmente pero garantiza encontrar el mejor punto dentro del rango definido.

Criterios de Selección y Métricas

GridSearch no solo busca, sino que decide basándose en una métrica de validación cruzada.

- **Para Regresión:** Suele optimizar el Error Cuadrático Medio (MSE) o el R^2 .
- **Para Clasificación (PD):** Se prioriza maximizar el AUC o el F-score para balancear precisión y recall.
- **Resultado Final:** El "Best Estimator" se reentrena con todo el conjunto de entrenamiento para maximizar el aprendizaje.

Implementación: Flujo en Scikit-Learn



```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score, plot_roc_curve

# 1. Instanciar y entrenar
model = LogisticRegression(penalty='l2', C=1.0)
model.fit(X_train, y_train)


# 2. Predecir probabilidades (no clases)
probs = model.predict_proba(X_test)[:, 1]

# 3. Evaluar
auc = roc_auc_score(y_test, probs)
```


A considerar - Overfitting



Underfitting




Balance



Overfitting

A considerar - Cross validation



Evitando el Overfitting: Regularización

Para modelos lineales con muchas variables financieras, aplicamos penalizaciones:

- **Lasso (L1):** Puede llevar coeficientes a cero. Útil para selección automática de variables.
- **Ridge (L2):** Reduce el tamaño de los coeficientes. Útil cuando hay alta correlación entre variables (Multicolinealidad).




Regularización

► Ridge:


$$\min_w \lambda ||w||^2 + ||e||^2 = \min_w \lambda ||w||^2 + (y - Xw)^\top (y - Xw)$$

► Lasso:

$$\min_w \lambda |w| + ||e||^2 = \min_w \lambda |w| + (y - Xw)^\top (y - Xw)$$



Regularización



Resumen de Aplicación

- **Regresión Logística:** Preferida por su interpretabilidad y cumplimiento regulatorio (Basilea).
- **SVM:** Potente para relaciones complejas, pero más difícil de explicar a un auditor.
- **Métricas:** Nunca confiar solo en la "Exactitud" (Accuracy) debido al desbalance de clases; priorizar AUC.