

Machine Learning para Finanzas

Clase 4

César Núñez Cuevas


`cnunezc@fen.uchile.cl`





UNIVERSIDAD

Finis Terrae

Workflow



Modelos Supervisados



1. Tratamiento del Desbalanceo: Remuestreo

En planificación financiera (ej. detectar impagos), la clase positiva suele ser minoritaria. Esto sesga al modelo hacia la clase mayoritaria.

- **Random Under-sampling:** Elimina aleatoriamente muestras de la clase mayoritaria. Riesgo: pérdida de información valiosa.
- **Random Over-sampling:** Duplica muestras de la clase minoritaria. Riesgo: induce al sobreajuste (overfitting).
- **SMOTE (Synthetic Minority Over-sampling Technique):** Crea muestras sintéticas interpolando entre vecinos cercanos de la clase minoritaria.
- **Validación:** El remuestreo **solo** debe aplicarse en el set de entrenamiento; el set de prueba debe permanecer con la distribución real.

2. Ajustes de Algoritmo y Métricas de Evaluación

Si no se desea alterar los datos, se puede ajustar cómo el modelo aprende.º cómo medimos su éxito.

- **Pesos de Clase (Class Weights):** Algoritmos como SVM o Random Forest permiten asignar una penalización mayor al error en la clase minoritaria (ej. `class_weight='balanced'`).
- **Cambio de Umbral (Thresholding):** En lugar de usar 0,5, se baja el umbral de decisión para capturar más casos de riesgo (aumentar el Recall).
- **Métricas Robustas:** Ignorar el *Accuracy*. Priorizar el uso de **Precision-Recall Curve**, **F-score** ($\beta > 1$ para priorizar recall) y el **Coeficiente Gini**.
- **Modelos de Detección de Anomalías:** En casos extremos (0.1 % de target), tratar el problema como detección de *outliers* (ej. Isolation Forest).

Criterios de División: Entropía e Impureza de Gini

Para decidir dónde "cortar" una variable, se utilizan métricas de impureza:

- **Impureza de Gini:** $G = \sum_{i=1}^C p_i(1 - p_i)$.
- **Entropía:** $H = - \sum_{i=1}^C p_i \log_2(p_i)$.
- En finanzas, Gini suele ser preferido por eficiencia computacional al clasificar clientes.

El Problema del Overfitting

Un árbol sin restricciones puede crecer hasta que cada hoja contenga un solo dato.

- Esto captura el ruido.^{en} lugar de la señal financiera.
- El modelo resultante tiene un error de entrenamiento nulo pero un error de test elevado.

Simulación de Árboles y Poda (Pruning)

La poda es el proceso de reducir el tamaño del árbol para mejorar la generalización.

- **Pre-pruning:** Detener el crecimiento por profundidad máxima o número mínimo de muestras por hoja.
- **Post-pruning (Cost Complexity Pruning):** Eliminar ramas que aportan poco valor predictivo tras el crecimiento completo.

Visualización: Estructura de Decisión para Churn

En un modelo de abandono de clientes (churn), el árbol prioriza variables clave:

- Nodo 1: ¿Antigüedad > 1 año?
- Nodo 2: ¿Número de productos > 2?
- Nodo 3: ¿Saldo en cuenta > \$500?

K-Nearest Neighbors (KNN)

KNN clasifica basándose en la proximidad en el espacio de características.

- No asume una forma funcional (No paramétrico).
- El valor de k es crítico: un k pequeño es sensible al ruido; un k grande suaviza demasiado las fronteras.

Distancias en KNN

La elección de la métrica de distancia altera el resultado:

- **Euclidiana:** $d(x, y) = \sqrt{\sum (x_i - y_i)^2}$.
- **Manhattan:** $d(x, y) = \sum |x_i - y_i|$.
- **Importante:** Requiere escalado previo de variables (ej. Ingresos vs. Edad).

Multi-Layer Perceptron (MLP)

El MLP es la base del Deep Learning para datos tabulares financieros.

- Capas: Entrada, Ocultas (Extracción de rasgos), y Salida (Clasificación).
- Utiliza funciones de activación no lineales (ReLU, Sigmoid) para capturar patrones complejos.

Entrenamiento del MLP: Backpropagation

El modelo aprende minimizando una función de pérdida (Loss Function).

- Se calculan gradientes mediante la regla de la cadena.
- En Churn financiero, ayuda a detectar interacciones no lineales que los árboles simples ignoran.

Trasfondo de los Métodos de Ensamble

La idea central es combinar múltiples modelos "débiles" para crear un modelo "fuerte".

- **Bagging:** Reduce la Varianza.
- **Boosting:** Reduce el Sesgo.

Random Forests (RF)

RF aplica Bagging a árboles de decisión con una restricción adicional:

- **Bootstrap:** Muestreo con reemplazo de los datos.
- **Feature Subsampling:** En cada nodo, solo se considera un subconjunto aleatorio de variables.

Ventajas del Random Forest en Finanzas

- Extremadamente robusto a valores atípicos (*outliers*).
- Proporciona una medida intrínseca de **Importancia de Variables** (*Feature Importance*).
- Excelente para datasets de churn donde hay desbalance de clases.

Entrenamiento para Churn Financiero

- Se entrena el bosque sobre el historial transaccional.
- Cada árbol "vota" si el cliente abandonará o no el banco.
- La mayoría determina la predicción final.

AdaBoost (Adaptive Boosting)

Primer algoritmo de boosting exitoso.

- Entrena modelos secuencialmente.
- Los ejemplos mal clasificados en una ronda reciben más "peso" en la siguiente.

Gradient Boosting Machines (GBM)

A diferencia de AdaBoost, GBM entrena nuevos modelos para predecir los **errores residuales** de los modelos anteriores.

$$F_{m+1}(x) = F_m(x) + h_m(x)$$

Optimiza una función de pérdida diferenciable arbitraria.

XGBoost: Extreme Gradient Boosting

Se ha convertido en el estándar de facto en banca y competiciones.

- **Regularización L1/L2:** Evita el sobreajuste.
- **Paralelización:** Entrenamiento mucho más rápido.
- **Manejo de valores nulos:** Aprende por defecto hacia qué rama enviar los datos faltantes.

Comparativa: Modelos Simples vs. Ensamblados

Modelo	Interpretación	Precisión	Riesgo Overfit
Árbol Simple	Alta	Baja	Muy Alto
Random Forest	Media	Alta	Bajo
XGBoost	Baja	Muy Alta	Moderado

Interpretación de la Matriz de Confusión

La matriz de confusión es la herramienta fundamental para desagregar el error del modelo y entender qué tipo de fallos estamos cometiendo.

Predicción	Valor Real	
	Negativo (0)	Positivo (1)
Negativo (0)	VN	FN
Positivo (1)	FP	VP

Interpretación de la Matriz de Confusión

La matriz de confusión es la herramienta fundamental para desagregar el error del modelo y entender qué tipo de fallos estamos cometiendo. **Cómo leer los cuadrantes:**

- **VN (Verdadero Negativo):** Clientes solventes correctamente identificados.
- **VP (Verdadero Positivo):** Clientes en default detectados con éxito.
- **FP (Falso Positivo):** *Error Tipo I.* Cliente bueno rechazado (Costo de oportunidad).
- **FN (Falso Negativo):** *Error Tipo II.* Cliente moroso aceptado (**Riesgo crítico**).

Regla de Oro: En finanzas, no todos los errores valen lo mismo. Un **FN** suele ser mucho más costoso que un **FP**, por lo que buscamos maximizar el *Recall* sin destruir la *Precisión*.

Métricas: Precisión vs. Recall


- **Precisión:** $Precision = \frac{TP}{TP+FP}$
"proporción de verdaderos positivos entre las predicciones positivas".
De los que dijimos que fallarían, ¿cuántos fallaron realmente?
- **Tasa de Falsos Positivos:** $FalsePositiverate = \frac{FP}{FP+TN}$
"proporción de falsos positivos entre los negativos reales"
- **(Recall - sensibilidad):** $Recall(TruePositiverate) = \frac{TP}{FN+TP}$
"proporción de verdaderos positivos entre los positivos reales". ¿Qué porcentaje de los morosos totales capturamos? Es vital para el área de riesgos.
- **Media Geométrica:** $Geom.mean = \sqrt{Precision \times Recall}$
- **Puntuación F (F-score):** $F-score = \frac{(\beta^2+1)}{\beta^2} \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}}$

Curva ROC (Receiver Operating Characteristic)

Visualiza el equilibrio entre la sensibilidad (tasa de verdaderos positivos) y la especificidad ($1 - \text{tasa de falsos positivos}$) al variar el umbral de decisión. Grafica la Tasa de Verdaderos Positivos (TVP) frente a la Tasa de Falsos Positivos (TFP) para todos los umbrales posibles.

- Representa la capacidad del modelo para separar las dos clases.
- Un modelo aleatorio sigue la diagonal de 45 grados.
- Un modelo perfecto se desplaza hacia la esquina superior izquierda.

ROC



AUC: Area Under the Curve

El **AUC** Proporciona una métrica única para comparar modelos. Un AUC de 1 representa un modelo perfecto, mientras que un valor de 0.5 sugiere que el modelo no distingue entre clases (igual al azar). Proporciona un número único para comparar modelos:

- **AUC = 0.5:** Sin capacidad predictiva (aleatorio).
- **0.7 - 0.8:** Desempeño aceptable en Scoring.
- **> 0.85:** Desempeño excelente.

Significado estadístico: Es la probabilidad de que el modelo asigne una probabilidad de default más alta a un cliente moroso elegido al azar que a uno solvente.

La Curva ROC y el AUC en Modelos No Lineales

La curva ROC ilustra la capacidad de discriminación del ensamble.

- El AUC (Área Bajo la Curva) resume el desempeño global.
- Un Random Forest suele superar al Árbol Simple al suavizar las fronteras de decisión.

¿Qué son los Hiperparámetros?

A diferencia de los parámetros (que el modelo aprende solo), los hiperparámetros los define el científico de datos antes del entrenamiento.

- **En Árboles:** La profundidad máxima o el número mínimo de muestras para una hoja.
- **En KNN:** El número de vecinos k .
- **En XGBoost/LightGBM:** La tasa de aprendizaje (learning rate) y el número de estimadores.

Estrategias de Búsqueda: Grid vs. Random Search

Para encontrar la combinación óptima, utilizamos métodos sistemáticos:

- **Grid Search:** Evaluación exhaustiva de todas las combinaciones posibles en una "malla" predefinida.
- **Random Search:** Selección aleatoria de combinaciones; suele ser más eficiente para encontrar el óptimo global con menos costo computacional.
- Ambos métodos requieren **Validación Cruzada (Cross-Validation)** para asegurar estabilidad.

El Flujo Maestro: Validación Cruzada

La búsqueda de hiperparámetros siempre debe ocurrir dentro del set de entrenamiento mediante **K-Fold Cross-Validation**:

- 1 Se divide el set de entrenamiento en K partes.
- 2 Se entrena en $K - 1$ y se valida en la restante.
- 3 Se repite K veces y se promedia el desempeño (ej. promedio de Recall o Gini).

Esto garantiza que los hiperparámetros elegidos no dependan de una división "afortunada" de los datos.

Resumen de Desempeño Observado

En contextos reales de banca:

- Los ensamblados reducen el error de generalización.
- La combinación de diversos modelos (Stacking) suele ofrecer el mejor resultado final.