

Machine Learning para Finanzas

Clase 4

César Núñez Cuevas


`cnunezc@fen.uchile.cl`





UNIVERSIDAD

Finis Terrae

Workflow



Modelos Supervisados



¿Qué es el Aprendizaje No Supervisado?

A diferencia de la clasificación (PD), aquí no tenemos una etiqueta "objetivo" (y).

- El algoritmo busca estructura oculta en los datos financieros.
- **Objetivo:** Agrupar observaciones similares y separar las disímiles.
- **Uso en Finanzas:** Segmentación de mercado, detección de fraude y diversificación de carteras.

El Concepto de Clustering

El clustering es la tarea de dividir un conjunto de datos en grupos (clusters).

- **Alta cohesión intra-cluster:** Los puntos dentro de un grupo son muy parecidos.
- **Alta separación inter-cluster:** Los grupos están bien distanciados entre sí.

Aplicaciones Reales en Banca

- ① **Banca Minorista:** Identificar grupos por comportamiento de gasto.
- ② **Gestión de Riesgos:** Agrupar préstamos con perfiles de pago atípicos.
- ③ **Seguros:** Detectar reclamaciones que no encajan en patrones normales (anomalías).

La Importancia de la Distancia

¿Cómo definimos "similitud"? Depende de la métrica de distancia:

- **Euclidiana:** Línea recta entre puntos (estándar).
- **Manhattan:** Suma de diferencias absolutas (robusta a outliers).
- **Coseno:** Mide el ángulo entre vectores (útil para perfiles de inversión).

Preprocesamiento: El Escalado es Vital

Como el clustering se basa en distancias, las variables deben estar en la misma escala.


- Sin escalado, una variable como "Patrimonio Total" dominaría sobre "Edad".
- **StandardScaler:** Media 0 y varianza 1.

Algoritmo K-Means: Trasfondo

Es el algoritmo de clustering más popular debido a su eficiencia.

- Es un método basado en **centroides**.
- El usuario debe definir K (número de grupos) de antemano.

K-Means



Funcionamiento de K-Means

- 1 Inicialización aleatoria de K centroides.
- 2 **Asignación:** Cada punto se une al centroide más cercano.
- 3 **Actualización:** El centroide se mueve al promedio de sus puntos.
- 4 Repetir hasta la convergencia.


Función de Costo: Inercia

K-Means busca minimizar la Suma de Cuadrados Dentro del Cluster (WCSS):

$$J = \sum_{j=1}^K \sum_{i \in C_j} \|x_i - \mu_j\|^2$$

Donde μ_j es el centroide del grupo j .


K-Means



Eligiendo K: El Método del Codo (Elbow)


- Graficamos la inercia vs. el número de clusters.
- El punto donde la caída de la inercia se ralentiza ("el codo") indica el K óptimo.

K-Means



Line plot between K and inertia

K-Means



Limitaciones de K-Means


- Asume que los clusters son esféricos y de igual tamaño.
- Muy sensible a la inicialización y a los *outliers* financieros.

Clustering Jerárquico: Aglomerativo

No requiere definir K al inicio. Crea una jerarquía de grupos.


- Comienza con cada punto como su propio cluster.
- Fusiona sucesivamente los pares más cercanos.

Clustering Jerárquico



El Dendrograma

Es una visualización en forma de árbol que permite ver las relaciones de proximidad y decidir dónde realizar el “corte” para definir los grupos.




Métodos de Enlace (Linkage)

Define cómo se calcula la distancia entre grupos:

- **Single Linkage:** Distancia mínima (produce clusters alargados).
- **Complete Linkage:** Distancia máxima (clusters compactos).
- **Ward:** Minimiza el aumento de la varianza total al fusionar.

Clustering Jerárquico



[Image source: https://github.com/rasbt/python-machine-learning-book/blob/master/code/ch11/images/11_05.png]

Ventajas del Jerárquico

- Muy útil para entender la taxonomía de productos financieros.
- Permite visualizar subgrupos dentro de grupos grandes.

Desventajas del Jerárquico



- Computacionalmente costoso en grandes datasets bancarios ($O(n^2)$ o $O(n^3)$).
- Una vez que se fusionan dos puntos, no se puede deshacer.

DBSCAN: Clustering basado en Densidad

Ideal para clusters de formas irregulares y para identificar ruido.

- **Epsilon (ϵ):** Radio de vecindad.
- **MinPoints:** Mínimo de puntos para formar una zona densa.

DBSCAN




Tipos de Puntos en DBSCAN


- **Core Points:** Puntos en zonas densas.
- **Border Points:** En la periferia de un cluster.
- **Noise (Ruido):** Puntos aislados (Anomalías financieras).

DBSCAN


DBSCAN point types



DBSCAN ϵ (epsilon)



DBSCAN min. points



Detección de Anomalías

DBSCAN es potente para detectar fraudes, ya que las transacciones fraudulentas no suelen pertenecer a ningún cluster denso de comportamiento normal.

Ventajas de DBSCAN

- No requiere definir K .
- Encuentra cualquier forma de cluster.
- Robusto a outliers.

Desventajas de DBSCAN

- No funciona bien con densidades variables.
- Es difícil elegir el ϵ adecuado en datos de alta dimensión.



Coeficiente de Silueta (Silhouette)

Mide qué tan bien está asignado un punto a su cluster:

$$s = \frac{b - a}{\text{máx}(a, b)}$$

a : Distancia media intra-cluster. b : Distancia media al cluster más cercano.

Silhouette analysis for KMeans clustering on sample data with $n_clusters = 5$



22. Interpretando la Silueta

- **Cercano a 1:** El punto está muy bien agrupado.
- **Cercano a 0:** Está en el límite entre dos clusters.
- **Negativo:** Probablemente asignado al cluster incorrecto.

Validación Externa vs Interna

- **Interna:** Solo usa los datos (Inercia, Silueta).
- **Externa:** Compara con etiquetas reales si existen (ej. ARI - Adjusted Rand Index).