

Machine Learning para Finanzas

Clase 8

César Núñez Cuevas

`cnunezc@fen.uchile.cl`



UNIVERSIDAD

Finis Terrae

1. NLP en el Ecosistema Financiero

El 80 % de los datos financieros no están estructurados (reportes, noticias, minutas).

- **Desafío:** Convertir el lenguaje humano en vectores numéricos procesables.
- **Señal Alpha:** Extraer sentimientos de noticias para predecir movimientos de mercado.
- **Cumplimiento:** Automatizar la revisión de contratos y regulaciones.

2. Limpieza de Datos I: Normalización

El texto crudo es ruidoso. El primer paso es la estandarización:

- **Conversión a minúsculas:** Evita que "Banco" y "banco" sean tratados como distintos.
- **Eliminación de puntuación y caracteres especiales:** Limpieza de ruido visual.
- **Manejo de números:** En finanzas, a veces se reemplazan por tokens (ej. "[NUM]") o se mantienen si son fechas clave.

3. Limpieza de Datos II: Tokenización y Stopwords

- **Tokenización:** Dividir el texto en unidades mínimas (palabras o sub-palabras).
- **Stopwords:** Eliminar palabras frecuentes que no aportan valor semántico (ej. "el", "de", "z").
- **Nota Financiera:** Palabras como "no." "pero" pueden ser stopwords estándar pero son críticas en análisis de sentimiento.

4. Limpieza de Datos III: Stemming vs Lemmatización

Reducción de palabras a su raíz:

- **Stemming:** Corte heurístico (ej. "Inversiones" → "Invers"). Rápido pero rudo.
- **Lemmatización:** Reducción a la forma de diccionario (ej. "Inversiones" → "Inversión"). Requiere análisis morfológico.
- En finanzas, la lemmatización es preferida para mantener la precisión técnica.

5. Representación de Texto: Bag of Words (BoW)

El modelo más simple: contar frecuencias.

- Crea una matriz donde cada columna es una palabra del vocabulario.
- **Problema:** Ignora el orden de las palabras y la importancia relativa.
"El mercado caez Çae el mercado" son idénticos.

6. TF-IDF: Ponderación de Importancia

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{\text{DF}(t)} \right)$$

- **TF (Term Frequency):** Qué tanto aparece la palabra en el documento.
- **IDF (Inverse Document Frequency):** Qué tan rara es la palabra en el corpus.
- Ayuda a resaltar términos específicos como "Default" o "Goodwill" frente a palabras genéricas.
- Corpus se le llama a un texto y Document-Term matrix cuenta la frecuencia de las palabras en el texto

7. Sentiment Analysis (Análisis de Sentimiento)


Clasificar la polaridad de un texto (Positivo, Negativo, Neutral).

- **Lexicon-based:** Uso de diccionarios financieros (ej. Loughran-McDonald).
- **ML-based:** Entrenar un clasificador (Naive Bayes, SVM) con textos etiquetados.
- **Etiquetas:** cada palabra se etiqueta en términos de:
 - Polaridad: negativo (-1) o positivo (+1)
 - Subjetividad: Subjetivo (0) o Hecho (+1)
- El sentimiento de una palabra varía dependiendo de en qué posición esté en la oración. Negación multiplica la polaridad por -0.5

8. Topic Modeling: LSA (Latent Semantic Analysis)

Descubrir temas ocultos mediante descomposición matemática.

- Utiliza SVD (Descomposición en Valores Singulares) sobre la matriz TF-IDF.
- Reduce la dimensionalidad capturando conceptos.^{en} lugar de palabras aisladas.
- Identifica si un reporte habla de Riesgo de Crédito.^o "Liquidez" sin etiquetas previas.




9. Similitud del Coseno (Cosine Similarity)

¿Cómo medir qué tan parecidos son dos documentos financieros?

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

- Mide el ángulo entre vectores de texto.
- Independiente de la longitud del documento.
- Valor cercano a 1 significa alta similitud semántica.


9. Similitud del Coseno (Cosine Similarity)



Male-Female



Verb tense



Country-Capital

$$v(\text{Italy}) - v(\text{Rome}) \sim v(\text{France}) - v(\text{Paris})$$

10. Limitaciones de los Modelos Clásicos

- **Sparsity:** Matrices gigantes con muchos ceros.
- **Falta de Semántica:** "Banco" (entidad) y "Banco" (asiento) se tratan igual.
- **Contexto:** No capturan relaciones de larga distancia entre palabras.

11. Word Embeddings: Vectores Densos

Representar palabras en un espacio continuo de baja dimensión (ej. 300 dimensiones).

- Palabras con significados similares están cerca en el espacio vectorial.
- Capturan relaciones complejas: $\text{Rey} - \text{Hombre} + \text{Mujer} = \text{Reina}$.


12. Word2Vec: Arquitecturas

Desarrollado por Google, entrena redes neuronales simples para aprender vectores:

- **CBOW (Continuous Bag of Words):** Predice la palabra central dado el contexto.
- **Skip-gram:** Predice las palabras del contexto dada la palabra central (mejor para palabras raras).

12. Word2Vec: Arquitecturas


Source Text	Training Samples						
<table><tr><td>The</td><td>quick</td><td>brown</td></tr></table> fox jumps over the lazy dog. ➡	The	quick	brown	(the, quick) (the, brown)			
The	quick	brown					
<table><tr><td>The</td><td>quick</td><td>brown</td><td>fox</td></tr></table> jumps over the lazy dog. ➡	The	quick	brown	fox	(quick, the) (quick, brown) (quick, fox)		
The	quick	brown	fox				
<table><tr><td>The</td><td>quick</td><td>brown</td><td>fox</td><td>jumps</td></tr></table> over the lazy dog. ➡	The	quick	brown	fox	jumps	(brown, the) (brown, quick) (brown, fox) (brown, jumps)	
The	quick	brown	fox	jumps			
<table><tr><td>The</td><td>quick</td><td>brown</td><td>fox</td><td>jumps</td><td>over</td></tr></table> the lazy dog. ➡	The	quick	brown	fox	jumps	over	(fox, quick) (fox, brown) (fox, jumps) (fox, over)
The	quick	brown	fox	jumps	over		



13. Word2Vec: El Input y la Capa Oculta

- **Input:** One-hot encoding de la palabra actual.
- **Capa de Proyección:** Una matriz de pesos que se convierte en nuestro ".Embedding".
- **Output:** Probabilidades (Softmax) de palabras vecinas.

13. Word2Vec



$$\underbrace{e_i^T \times W_{N \times d}}_h \times W_{d \times N} \rightarrow^{\text{softmax}} \mathbb{P}(\text{word}_j | \text{word}_i)$$

We maximize $\frac{1}{T} \sum_{t=1}^T \sum_{-c \leq k \leq c, k \neq 0} \log(p(w_{i+k} | w_i))$ where $p(o|c) = \exp(v_o^T v_c) / \sum_{w=1}^V \exp(u_w^T v_c)$

14. GloVe (Global Vectors)

A diferencia de Word2Vec (basado en ventanas locales), GloVe utiliza estadísticas globales.

- Factoriza la matriz de co-ocurrencia de todo el corpus.
- Combina lo mejor de LSA (estadística global) y Word2Vec (contexto local).

counts	I	like	enjoy	deep	learning	NLP	flying	.
I	0	2	1	0	0	0	0	0
like	2	0	0	1	0	1	0	0
enjoy	1	0	0	0	0	0	1	0
deep	0	1	0	0	1	0	0	0
learning	0	0	0	1	0	0	0	1
NLP	0	1	0	0	0	0	0	1
flying	0	0	1	0	0	0	0	1
.	0	0	0	0	1	1	1	0

Example corpus:

- I like deep learning.
- I like NLP.
- I enjoy flying.

$$J(\theta) = \frac{1}{2} \sum_{i,j=1}^W f(P_{ij})(u_i^T v_j - \log P_{ij})^2$$

15. Visualización de Embeddings Financieros

Mediante PCA o t-SNE, podemos ver clusters:

- Cluster 1: Monedas (USD, EUR, JPY).
- Cluster 2: Acciones (AAPL, MSFT, GOOG).
- Cluster 3: Términos de riesgo (Default, Bankruptcy, Distress).

16. Modelos Secuenciales (RNN)

El lenguaje es una secuencia. Las Redes Neuronales Recurrentes (RNN) tienen "memoria".

- Mantienen un estado oculto que se actualiza palabra tras palabra.
- **Problema:** Desvanecimiento del gradiente (olvidan el inicio de oraciones largas).

17. LSTM (Long Short-Term Memory)

Diseñada para recordar información a largo plazo.

- Introducen la "Celda de Estado" que actúa como una autopista de información.
- Ideal para analizar reportes anuales donde la conclusión depende de datos al inicio del texto.

18. Arquitectura LSTM: Las Compuertas (Gates)

- **Forget Gate:** Decide qué información borrar.
- **Input Gate:** Decide qué nueva información guardar.
- **Output Gate:** Decide qué parte del estado mostrar como salida.

19. El problema de la Recurrencia

- El procesamiento secuencial es lento (no se puede paralelizar).
- Incluso con LSTM, el contexto muy lejano es difícil de capturar.
- **Solución:** Mecanismos de Atención.

20. Transformers: La Revolución

Presentados en "Attention Is All You Need" (2017).


- Eliminan la recurrencia. Procesan todas las palabras en paralelo.
- Utilizan **Self-Attention** para entender la relación de cada palabra con todas las demás.

21. Mecanismo de Atención: Query, Key, Value

El modelo asigna pesos a las palabras según su relevancia:

- **Query:** ¿Qué estoy buscando?
- **Key:** ¿Qué información tengo?
- **Value:** El contenido de la información.

21. Mecanismo de Atención: Query, Key, Value



22. Modelos Pre-entrenados: BERT y GPT

- **BERT:** Entiende el contexto bidireccional (útil para clasificación).
- **GPT:** Generativo, predice la siguiente palabra (útil para resúmenes).
- **FinBERT:** Versión de BERT entrenada exclusivamente con textos financieros.