

Machine Learning para Finanzas

Clase 10

César Núñez Cuevas

`cnunezc@fen.uchile.cl`



UNIVERSIDAD

Finis Terrae

¿Qué es un Large Language Model (LLM)?

- **Definición:** Redes neuronales profundas basadas en la arquitectura Transformer, entrenadas con miles de millones de parámetros y volúmenes masivos de texto.
- **Mecanismo Clave:** El mecanismo de *Self-Attention* (Auto-atención) permite capturar relaciones de largo alcance entre palabras dentro de un texto.
- **Objetivo de Entrenamiento:** Predicción del siguiente token (Modelado de Lenguaje Autorregresivo):

$$P(w_1, w_2, \dots, w_n) = \prod_{i=1}^n P(w_i \mid w_1, w_2, \dots, w_{i-1}) \quad (1)$$

La Arquitectura Transformer

Componentes Principales:

- **Encoder-Decoder:** Codificación del contexto y generación secuencial (ej. T5).
- **Decoder-Only:** El estándar actual para modelos generativos como GPT y Gemini.

Ventajas sobre RNNs/LSTMs:

- **Paralelización:** No requiere procesamiento secuencial en el entrenamiento, permitiendo usar hardware masivo (GPUs/TPUs).
- **Contexto Expandido:** Ventanas de contexto que escalan desde miles hasta millones de tokens.

Leyes de Escalamiento y Propiedades Emergentes

- **Leyes de Escalamiento (Scaling Laws):** El rendimiento de los LLMs sigue una ley de potencia predecible respecto al tamaño del modelo, el conjunto de datos y el cómputo invertido.
- **Habilidades Emergentes:** Capacidades que no están presentes en modelos pequeños pero aparecen súbitamente al superar ciertos umbrales de escala.
- **Ejemplos:** Razonamiento lógico multi-paso, comprensión de metáforas complejas, generación de código avanzado sin entrenamiento explícito.

La Revolución Multimodal

- **¿Qué es la Multimodalidad?** La capacidad de un modelo de procesar, comprender y generar información de múltiples fuentes o modalidades simultáneamente (Texto, Imágenes, Audio, Video, Código).
- **Fusión de Datos:** En lugar de mapear imágenes a texto mediante etiquetas, el modelo proyecta representaciones visuales y textuales en un mismo espacio latente compartido.
- **Ejemplos Destacados:** Gemini (nativo multimodal), GPT-4o, Claude 3.5 Sonnet.

¿Cómo funciona la Multimodalidad?

- **Encoders de Modalidad Específica:** Uso de Vision Transformers (ViT) para imágenes y encoders especializados para audio.
- **Proyección Lineal / Cross-Attention:** Un puente matemático alinea los embeddings de la imagen o el audio con el espacio de tokens de texto del LLM.
- **Tokenización Unificada:** Modelos de última generación tratan parches de imágenes o fragmentos de audio exactamente como si fuesen tokens lingüísticos tradicionales.

Casos de Uso de la Multimodalidad

- **Análisis de Documentos Complejos:** Comprensión de PDFs con gráficos financieros, diagramas de flujo y tablas mixtas sin necesidad de OCR previo.
- **Asistencia en Tiempo Real:** Interfaces de voz con baja latencia que interpretan emociones en el tono de voz y reaccionan a entradas de video en vivo.
- **Robótica y Visión:** Generación de trayectorias y planes de acción para agentes físicos basados en la entrada de cámaras web y sensores.

Model Context Protocol (MCP)

- **¿Qué es MCP?** Un estándar abierto y universal introducido para conectar modelos de IA con fuentes de datos y herramientas de manera uniforme.
- **El Problema de la Fragmentación:** Antes de MCP, cada herramienta, base de datos o API requería una integración personalizada única para cada framework de IA.
- **La Solución de MCP:** Actúa como una interfaz estandarizada (un "USB-C para IA"), permitiendo que cualquier cliente de IA se conecte a cualquier servidor de datos compatible.

Arquitectura de MCP: Cliente - Servidor

- **MCP Client:** Aplicaciones de IA (como entornos de desarrollo o plataformas de chat) que exponen capacidades del modelo.
- **MCP Server:** Pequeños servicios ligeros que exponen datos o herramientas de manera segura a través del protocolo.
- **Tres Capas Fundamentales:**
 - ① **Prompts:** Plantillas predefinidas que el servidor expone al cliente.
 - ② **Resources:** Datos legibles (archivos, bases de datos, logs, contexto de Git).
 - ③ **Tools:** Acciones ejecutables por la IA con aprobación del usuario (escribir código, APIs externas).

Beneficios del Estándar MCP

- **Desacoplamiento:** Los desarrolladores de herramientas no necesitan preocuparse por los detalles de la API interna del LLM, y viceversa.
- **Security Boundaries:** El servidor MCP actúa como una frontera explícita, determinando exactamente a qué archivos o comandos tiene acceso la IA de forma segura.
- **Ecosistema Abierto:** Integración nativa con repositorios de código, bases de datos SQL/NoSQL, servicios en la nube y herramientas locales.

¿Qué es un Agente de IA?

- **Definición:** Sistemas autónomos impulsados por un LLM como cerebro central, capaces de percibir su entorno, tomar decisiones, planificar estrategias y ejecutar acciones utilizando herramientas.
- **Diferencia con los Prompts Simples:** Un prompt tradicional es síncrono (pregunta-respuesta). Un agente opera en un bucle asíncrono y continuo hasta resolver el objetivo asignado.
- **Fórmula Clave:**
$$\text{Agente} = \text{LLM} + \text{Memoria} + \text{Planificación} + \text{Uso de Herramientas}.$$

Componentes del Agente: Planificación y Memoria

- **Planificación (Planning):**

- ▶ **Deconstrucción de Tareas:** Dividir metas complejas en subtarefas manejables.
- ▶ **Reflexión y Auto-Crítica:** Evaluar outputs previos para corregir el rumbo en tiempo real (ej. marcos ReAct o Chain-of-Thought).

- **Memoria (Memory):**

- ▶ **Corto Plazo:** Todo el contexto disponible dentro de la ventana de tokens durante la ejecución.
- ▶ **Largo Plazo:** Recuperación de información histórica o persistente mediante bases de datos vectoriales (RAG).

Patrones de Diseño Agenciales Avanzados

- **Reflection / Self-Correction:** El agente genera un resultado, un módulo crítico lo evalúa y el agente itera para refinar el resultado.
- **Tool Use (Function Calling):** Capacidad del LLM para estructurar argumentos JSON precisos destinados a ejecutar código o APIs externas.
- **Sistemas Multi-Agente:** División del trabajo donde múltiples agentes con roles especializados (ej. Programador, Tester, Mánager) colaboran para resolver un problema.

LLMs y Agentes en el Flujo de Machine Learning

- **Generación de Características (Feature Engineering):** Los LLMs proponen transformaciones matemáticas y lógicas sobre los datos tabulares basándose en la comprensión semántica de las columnas.
- **AutoML Avanzado:** Agentes que escriben, ejecutan y depuran scripts de entrenamiento en PyTorch o XGBoost de forma iterativa basándose en las métricas de validación.
- **Etiquetado de Datos:** Clasificación masiva de datasets no estructurados utilizando arquitecturas de *Zero-Shot* o *Few-Shot Learning*.

Generación de Datos Sintéticos

- **Solución a la Escasez de Datos:** Uso de LLMs para simular texto, logs de comportamiento o datos estructurados difíciles de obtener debido a regulaciones de privacidad.
- **Alineación de Modelos:** Los LLMs más grandes (ej. frontier models) generan instrucciones complejas para destilar y entrenar modelos más pequeños y eficientes (*Knowledge Distillation*).
- **Casos de Borde (Edge Cases):** Creación dirigida de ejemplos anómalos o de fallos para mejorar la robustez de modelos predictivos tradicionales.

Análisis de Sentimiento a Escala

- **Fuentes de Información:** Reportes trimestrales (10-K, 10-Q), transcripciones de llamadas de ganancias (*Earnings Calls*), noticias y redes sociales.
- **Más allá del "Positivo/Negativo":** Los LLMs identifican matices semánticos sutiles en la guía financiera de los CEOs, calificando el riesgo, la incertidumbre y el optimismo estructural.
- **Integración Predictiva:** El sentimiento extraído se convierte en un factor cuantitativo (*alpha signal*) para modelos de series temporales de precios.

Procesamiento Automatizado de Reportes Multimodales

- **El Reto:** Los reportes financieros combinan extensos bloques de texto técnico con tablas contables densas e infografías de rendimiento.
- **Solución Multimodal + RAG:** Extracción directa de métricas financieras clave cruzando los pies de página de los gráficos con el balance general.
- **Conciliación Automatizada:** Auditoría automática de inconsistencias entre los datos reportados visualmente y el texto descriptivo adjunto.

Agentes Inteligentes aplicados al Trading Cuantitativo

- **Generación de Estrategias:** Agentes que leen literatura académica sobre finanzas, extraen las fórmulas matemáticas subyacentes y codifican backtests en Python de forma autónoma.
- **Monitoreo de Mercado 24/7:** Agentes multimodales que supervisan múltiples pantallas de datos, noticias geopolíticas repentinas e indicadores macroeconómicos en tiempo real.
- **Optimización Dinámica de Portafolios:** Ajuste de pesos de activos basado en condiciones cambiantes del mercado interpretadas cualitativa y cuantitativamente.

Gestión de Riesgos, Compliance y RegTech

- **Anti-Money Laundering (AML):** Agentes que analizan grafos de transacciones complejas y reportan patrones sospechosos redactando el reporte oficial automáticamente.
- **Monitoreo Normativo:** Seguimiento automatizado de las normativas financieras globales (ej. SEC, ESMA, Basilea) para validar el cumplimiento de las políticas internas de la firma.
- **Evaluación de Riesgo Crediticio Extendido:** Incorporación de datos alternativos no estructurados para evaluar el riesgo de impago en PYMEs o individuos.

Retos en la Implementación Financiera

- **Alucinaciones:** En finanzas, un dato erróneo o inventado por el modelo puede implicar pérdidas multimillonarias o sanciones legales graves.
- **Latencia:** El procesamiento a través de LLMs complejos no es apto para trading de alta frecuencia (HFT), requiriendo un balance costo/velocidad.
- **Explicabilidad (Black Box):** Los reguladores financieros exigen saber exactamente *por qué* se tomó una decisión crediticia o de inversión; los LLMs son inherentemente opacos.

Hacia dónde vamos: Ecosistemas Autónomos

- **Estandarización Absoluta (MCP):** Interconexión nativa de todas las aplicaciones financieras corporativas con inteligencias artificiales centralizadas y locales.
- **Razonamiento Avanzado:** Modelos orientados a la computación en tiempo de inferencia (*Inference-Time Compute*) que piensan durante minutos antes de dar una respuesta a problemas financieros complejos.
- **Soberanía de Modelos:** Transición de APIs genéricas de terceros hacia modelos propios de código abierto, especializados y ejecutados de forma privada.

Conclusiones Clave

- **Convergencia:** Los LLMs ya no son meros generadores de texto; se han convertido en motores de razonamiento multimodal y agencial.
- **Infraestructura Universal:** Estándares como MCP eliminan las barreras técnicas de conexión con el mundo real.
- **Impacto Sectorial:** La fusión de datos cuantitativos tradicionales de ML con las capacidades cualitativas y autónomas de los agentes está redefiniendo la industria financiera moderna.

¡Muchas gracias por su atención!

¿Preguntas y comentarios?